

FÉDÉRATION FRANÇAISE DES ÉCHECS × CAVALIER DATA

Un coach IA pour les ouvertures d'échecs

Accompagner les jeunes espoirs pendant leur entraînement autonome

Richard Hugou

IA Engineer — Soutenance de projet — Août 2026

Besoin et contexte

Le constat à la FFE

- **60 000 licenciés**, dont ~60 % de jeunes espoirs.
- Quelques centaines d'entraîneurs qualifiés sur le territoire.
- **Le goulot d'étranglement est humain** : impossible d'offrir un suivi quotidien individualisé le soir ou entre les rondes de tournoi.

Le cas d'usage : Léa, 12 ans

- Prépare ses championnats et veut réviser son répertoire ce soir.
- Son entraîneur n'est pas disponible.
- **Mission du POC** : un répétiteur interactif disponible 24/7 pour l'accompagner *pendant* qu'elle joue.

Les 4 capacités attendues de l'agent

- 1. Jouer** : proposer les coups recommandés par la théorie des maîtres.
- 2. Expliquer** : justifier les plans stratégiques avec sources fiables.
- 3. Conseiller** : recommander des vidéos pédagogiques ciblées.
- 4. Évaluer** : analyser objectivement toute sortie de théorie via Stockfish.

L'application en action

Chessboard

Tu joues : ▲ les Blancs ▲ les Noirs

Travailler une ouverture :

Italiane Espagnole Sicilienne Française

Caro-Kann Gambit dame Est-indienne Anglaise

Lancer l'IA sur cette position ↶ Annuler le coup

En théorie Italian Game C50

Coups recommandés par la théorie 48,726 parties de maîtres

Fc5 (fou f8)

25,481

Cf6 (cavalier g8)

21,370

Fe7 (fou f8)

1,043

d6 (pion d7)

647

g6 (pion g7)

129

Partie de référence : Caruana, Fabiano – Carlsen, Magnus (2020)

Deux options sérieuses : Fc5 (25 481 parties) ou Cf6 (21 370). La théorie est bien balisée avec des milliers de références. Tu dois choisir entre le fou en c5 et le cavalier en f6 pour continuer la partie italienne Giuoco Piano.

Sources : Base masters — Lichess Opening Explorer (CC0) · Corpus (CC BY-SA) — https://fr.wikipedia.org/wiki/Partie_italienne · Corpus (CC BY-SA) — https://fr.wikipedia.org/wiki/Partie_italienne_Giuoco_Piano · Corpus (CC BY-SA) — https://en.wikibooks.org/wiki/Chess_Opening_Theory/1._e4/1...e5/2._Nf3/2...Nc6/3._Bc4

Démonstration en vidéo

Scénario complet en conditions réelles (~4 min) :
Loom · 3-4 coups · Conseils RAG · Sortie de théorie Stockfish

Cavalier Data x FFE

Interface Angular 17 en direct

3 / 18

Parcours utilisateur

1. Orientation & Choix

L'élève choisit son camp (ex: les Blancs).
L'échiquier s'oriente immédiatement et
l'ouverture cible (Partie Italienne) est
sélectionnée.

2. Jeu théorique

L'élève joue ses coups sur le plateau.
L'agent joue automatiquement la
réplique des maîtres Lichess la plus
fréquente (1.e4 e5, 2.Cf3 Cc6).

3. Conseils sourcés


À 3.Fc4, « Demander à Chessbot »
affiche les coups des maîtres, les
flèches tactiques, la synthèse sourcée et
la vidéo YouTube associée.

4. Déviation moteur

Sur un coup hors théorie (ex: 4.g4?!),
l'agent bascule instantanément sur
Stockfish pour fournir une évaluation
objective chiffrée (-1,47 cp).

Principe directeur : les faits proviennent des moteurs spécialisés, le LLM intervient uniquement pour la formulation.

Architecture logicielle



Clé pivot FEN

La chaîne transmet la position standardisée de bout en bout sans ambiguïté.


Milvus vs MongoDB

Milvus stocke la connaissance vectorisée ; **MongoDB** gère le cache applicatif transverse.

Routage déterministe

Le seuil de parties maîtres décide du passage théorie/moteur de manière fiable.

Orchestration de l'agent



Scénario nominal (Italienne)

Coup 3.Fc4 → Lichess fournit Fc5/Cf6 → Milvus extrait les fiches du rayon → le LLM rédige le plan stratégique.

Scénario de déviation (Sortie)

Coup 4.g4?! → < 5 parties de référence → bifurcation immédiate vers Stockfish → évaluation -1,47 cp.

Gisement de données


4 sources documentaires complémentaires :

- **Référentiel des ouvertures** : nomenclature et codes ECO officiels
- **Lichess Explorer** : base de 2 M+ parties et statistiques maîtres
- **Wikipédia / Wikibooks** : corpus encyclopédique structuré
- **YouTube** : métadonnées et horodatages des cours vidéo

Pipeline ETL rejouable et idempotent :

extraction (manifeste signé) → nettoyage → fiches → vecteurs → Milvus

Périmètre validé : **156 pages extraites** → **477 fiches structurées** (95 positions FEN calculées, 0 échec).



Entonnoir réel du corpus (notebook 03) : 3 251 pages disponibles → 161 retenues → 477 fiches.

Recherche sémantique



Espace vectoriel unifié

Modèle multilingue (1024 dimensions) alignant naturellement les concepts en français et anglais.

Filtrage par rayon d'ouverture


Recherche restreinte au rayon actif : empêche la récupération de sources hors du périmètre concerné.

Performances mesurées

Recherche exécutée en **7 à 11 ms** · Séparation sémantique cible/hors-sujet portée de 0,29 à **0,50**.

Performances mesurées

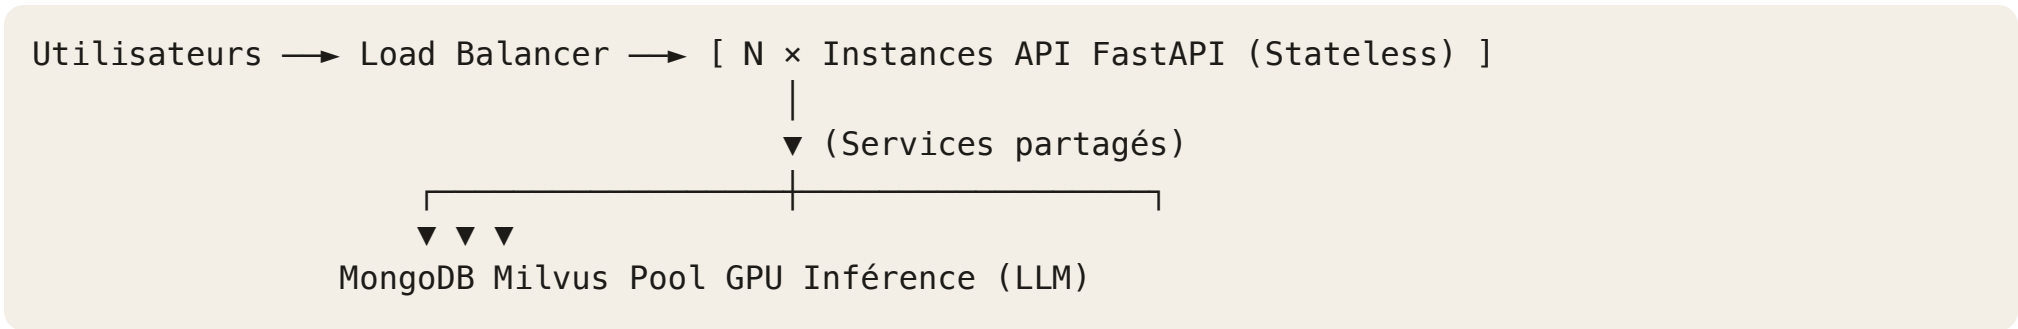
Indicateur clé	Objectif	Résultat mesuré
Coups illégaux en sortie	0	0 sur 56 testés
recall@5 (Gold Set 25 questions)	>= 0,80	1,0 (tracé MLflow)
Abstention sur les pièges	5 / 5	5 / 5 (filtrage par rayon)
Réponses avec sources valides	100 %	100 % (garanti par pipeline)
Recherche vectorielle Milvus	< 100 ms	7–11 ms (p95)
Latence Cloud GPU T4 (avec LLM)	p95 < 8 s	1,81 s (p50) · 2,41 s (p95)
Latence Local CPU (avec LLM)	p95 < 8 s	2,69 s (p50) · 6,35 s (p95)
Coût d'API LLM	0 €	0,00 € (modèle open source)



Latences mesurées sur le scénario de démo (notebook 05, 3 répétitions par position).

Architecture de déploiement

Architecture cible industrielle (Scalabilité horizontale)



- Séparation nette : compute API répliquable à volonté, bases mutualisées, pool GPU isolé.

Preuve réelle POC (Déployée)

- **Hugging Face Spaces**
- GPU NVIDIA T4 (16 Go VRAM)
- Stack complète embarquée avec Ollama CUDA, Stockfish et Milvus Lite
- Déploiement automatisé par CI/CD GitHub Actions
- Facturation à l'usage : **0,40 \$/h**

Dimensionnement et montée en charge

Facteurs limitants par composant

- **API FastAPI** : Stateless → réplication horizontale simple.
- **Stockfish** : CPU parallélisable (~0,8 s / coup).
- **Milvus & MongoDB** : Services partagés légers (7–11 ms).
- **Inférence LLM** : **Goulot principal** → dimensionné par le pool GPU.

Scénarios d'hypothèses de charge (Base FFE : 60 000 licenciés)

Hypothèse d'utilisation : 30 analyses / utilisateur / mois.

Scénario	Utilisateurs	Volume mensuel	Débit moyen	Cible GPU
Scénario 1 %	600 users	18 000 req/mois	~0,25 req/min	1 GPU partagé
Scénario 5 %	3 000 users	90 000 req/mois	~1,25 req/min	1 à 2 GPU
Scénario 10 %	6 000 users	180 000 req/mois	~2,50 req/min	2 à 3 GPU (autoscaling)

Coûts de fonctionnement

Postes de dépenses opérationnelles (Scénario cible 5 %)

Poste de coût	Composant	Estimation mensuelle
Inférence GPU	Pool GPU (instances T4 / L4 à l'usage)	~150 à 280 € / mois
API & Compute	Instances FastAPI stateless (CPU / RAM)	~30 à 50 € / mois
Bases de données	Milvus managé + MongoDB managé	~50 à 80 € / mois
Stockage & Logs	Métriques, monitoring, sauvegardes	~20 € / mois
APIs Externes	Modèles open source + YouTube API	0,00 €
TOTAL OPEX	Service en production (3 000 users)	~250 à 430 € / mois

Investissement Build (POC)

- **Développement POC** : ~25 à 30 jours-homme.
- **Stack 100 % open source** : aucune redevance de licence logicielle propriétaire.
- **Maîtrise budgétaire** : le coût reste dominé par le compute GPU ajustable selon l'usage.

YouTube dans le POC

Position de l'élève → Détection ouverture → YouTube Data API v3 → **Ressources vidéo recommandées**

Ce que fait l'application aujourd'hui

- L'agent identifie l'ouverture jouée sur l'échiquier.
- Il interroge l'API officielle YouTube Data pour extraire les vidéos explicatives pertinentes.
- Affichage direct : titre officiel, nom de la chaîne, durée et lien cliquable.
- **Conformité stricte** : exploitation des métadonnées seules, aucun téléchargement de flux.

Panneau vidéo intégré

L'élève dispose immédiatement de cours vidéo de grands maîtres adaptés à son ouverture sans quitter l'interface d'entraînement.

Analyse vidéo : évolution étudiée

Vidéo 15 min → 180 frames (1/5s) → ~30 positions clés → Détection FEN → **FEN ↔ vidéo ↔ timestamp**

Aujourd'hui (POC) : Position → Vidéo

Recommandation globale par nom d'ouverture :
« Voici 3 vidéos sur la Partie Italienne. »

Après analyse vidéo : Vidéo → Position

Recommandation directe au timestamp exact :
« Cette position exacte est expliquée à 4:32 dans cette vidéo. »

On part de la vidéo pour extraire les positions jouées et les transmettre à l'agent existant via la clé FEN.

Faisabilité et limites de l'analyse vidéo

1. Approche MVP : Transcripts-first + Vision 2D

- Reconstruire d'abord les coups cités dans le transcript textuel via python–chess.
- Utiliser la vision par ordinateur 2D uniquement pour confirmer la position et caler l'horodatage exact (~3 min CPU / vidéo).

2. Chiffrage de l'étude (Partie 2)

- **Build MVP** : 30 à 40 jours-homme (budget estimé : 15 à 20 k€).
- **Coût unitaire Run** : ~0,10 à 0,15 € / vidéo (à 1 000 vidéos/mois).
- **Statut** : Étude de faisabilité livrée — développement hors POC.

Limites & Risques identifiés dans la note

- Risque juridique (CGU YouTube & droit d'auteur) atténué par le traitement des chaînes partenaires sous licence.
- Échiquiers 3D / angles inclinés exclus du MVP (réservés à une version V2).

Résumé du POC

Agent fonctionnel

Reconnaissance théorique immédiate, explications pédagogiques sourcées, bascule moteur Stockfish.

Architecture maîtrisée

Orchestration déterministe LangGraph, Stockfish UCI, base vectorielle Milvus, cache transverse MongoDB.

Gisement de données

Pipeline ETL rejouable (4 sources, 477 fiches structurées, 95 FEN de référence validés).

Performances prouvées

0 coup illégal sur 56 positions, latence sous 2,5 s sur GPU Cloud T4 (p95 = 2,41 s).

Déploiement éprouvé

Conteneurisation locale reproductible (2 min 09) et vitrine cloud GPU opérationnelle sur Hugging Face Spaces.

Étude vidéo livrée

Note de cadrage, architecture MCP, faisabilité technique et modèle de coûts formalisés.

→ Place à la démonstration en direct et aux échanges.

SESSION INTERACTIVE

Démonstration en direct

Parcours nominal (Partie Italienne), demande de conseils sourcés, sortie de théorie sur Stockfish et exploration du code.

Application locale

`http://localhost:4200`

Vitrine Cloud GPU T4

`trikwi-p13-agent-ehecs.hf.space`

Merci.

Richard Hugou

IA Engineer — Cavalier Data

Dépôt : <https://github.com/richardhugou/p13-agent-ia-echecs>
Vitrine : <https://trikwi-p13-agent-echecs.hf.space>