

SOUTENANCE · PREUVE DE CONCEPT

Un coach IA pour les ouvertures d'échecs

Preuve de concept pour la Fédération Française des Échecs

Richard Hugou — IA Engineer junior, Cavalier Data · Soutenance — août 2026 · Mission POC — 2 semaines



L'histoire et le besoin

La FFE prépare ses jeunes espoirs aux championnats d'Europe. **60 000 licenciés**, **~60 % de jeunes**, quelques centaines d'entraîneurs diplômés — **le goulot d'étranglement, c'est l'humain.**

Imaginez **Léa, 12 ans** : elle veut travailler ses ouvertures ce soir, son entraîneur n'est pas disponible.
La commande d'Alan : **un POC en deux semaines** — une IA qui l'accompagne *pendant qu'elle joue*.

Ce que l'IA doit savoir faire pour elle :

1. proposer les coups reconnus par **la théorie**
2. **expliquer** les idées en citant ses sources
3. recommander des **vidéos** adaptées
4. **évaluer objectivement** quand elle sort des sentiers battus

L'application en action

Chessboard

Tu joues : ▲ les Blancs ▲ les Noirs

Travailler une ouverture :

Italienne Espagnole Sicilienne Française

Caro-Kann Gambit dame Est-indienne Anglaise

Lancer l'IA sur cette position ⌵ Annuler le coup

En théorie Italian Game C50

Coups recommandés par la théorie 48,726 parties de maîtres

Fc5 (fou f8)		25,481
Cf6 (cavalier g8)		21,370
Fe7 (fou f8)		1,043
d6 (pion d7)		647
g6 (pion g7)		129

Partie de référence : Caruana, Fabiano – Carlsen, Magnus (2020)

Deux options sérieuses : Fc5 (25 481 parties) ou Cf6 (21 370). La théorie est bien balisée avec des milliers de références. Tu dois choisir entre le fou en c5 et le cavalier en f6 pour continuer la partie italienne Giuoco Piano.


Sources : Base masters — Lichess Opening Explorer (CC0) · Corpus (CC BY-SA) — https://fr.wikipedia.org/wiki/Partie_italienne · Corpus (CC BY-SA) — https://fr.wikipedia.org/wiki/Partie_italienne_Giuoco_Piano · Corpus (CC BY-SA) — https://en.wikipedia.org/wiki/Chess_Opening_Theory/1_e4/1...e5/2_Nf3/2...Nc6/3_Bc4

Vidéo Loom

Cavalier Data x FFE

3 / 13


Le parcours de l'élève : un scénario suivi jusqu'au bout



Les faits proviennent des outils spécialisés ; le LLM intervient uniquement pour formuler la réponse.


1. **Choix du camp** : « je joue les Blancs » (un seul jeu de pièces, point de vue joueur).
2. **Point de départ** : l'Italienne (parmi 8 ouvertures du manifeste), ou position libre.
3. **Réponse adverse automatique** : l'agent joue le coup le plus joué par les maîtres.
4. **Détection hors théorie** : signalement immédiat et passage de main.
5. **Demande d'analyse (« Demander à Chessbot »)** : coups + stats, flèches, explication sourcée, vidéos.
6. **Évaluation tactique** : calcul objectif Stockfish sur coup douteux (-1,47 cp).

Qui communique avec qui : et pourquoi



Le **FEN** (position standardisée) est la clé pivot entre toutes les briques. Le routeur est **déterministe**. Chaque brique dispose d'un repli.

L'orchestration : le chemin d'une position




Un seul parcours à retenir : Léa joue 3.Fc4 → Italienne identifiée → **en théorie** → Fc5/Cf6 avec leurs statistiques → fiches du rayon italienne → vidéos → réponse rédigée et sourcée.

Sur 4.g4?! : **hors théorie** → le moteur mesure (-1,47) au lieu de réciter. **Le LLM ne choisit jamais un coup.**

La base documentaire : retrouver une information par son sens

Exemple de recherche sémantique : « *pourquoi le fou vise f7 ?* » (aucun mot-clé exact ne relie la question à la page « Giuoco Piano »).



Les 477 fiches (FR + EN, dans le **même espace vectoriel 1024d**) sont indexées une fois. La recherche par similarité cosinus s'effectue **dans le rayon de l'ouverture active** : hors bibliothèque, zéro fiche transmise.

Performances mesurées : recherche **7-11 ms** · séparation sémantique cible/hors-sujet portée de 0,29 à **0,50** (notebook 02).

Construction de la base documentaire


4 sources pour 4 fonctions :

- Nomenclature : référentiel `chess-openings` (CC0)
- Coups & stats maîtres : API Lichess (2 M+ parties, CC0)
- Corpus encyclopédique : Wikipédia FR + Wikibooks EN (CC BY-SA)
- Ressources complémentaires : YouTube (métadonnées seules)

Pipeline ETL rejouable et idempotent :

extraction (périmètre signé) → nettoyage → fiches → vecteurs
→ Milvus

Périmètre validé par manifeste versionné : **156 pages extraites** → **477 fiches structurées** (95 FEN de référence calculés, 0 échec).



Entonnoir réel du corpus (notebook 03) : 3 251 pages disponibles → 161 retenues → 477 fiches.

Résultats et performances


INDICATEUR	RÉSULTAT MESURÉ
Coups illégaux en sortie	0 / 56 (scénario e2e complet)
recall@5 (Gold Set 25 questions)	1,0 (runs A/B sous MLflow)
Abstention sur les pièges	5 / 5 (filtrage déterministe par rayon)
Réponses sourcées	100 % (garanti par le pipeline)
Recherche vectorielle p95	7-11 ms
Latence avec LLM p95	2,41 s en ligne (GPU T4) · 6,3 s local (CPU)
Coût LLM du POC	0,00 € (inférence locale sur l'hôte et GPU T4)

Local : poste complet (LLM local Qwen 3.5)

p50 2,7 s · p95 6,3 s : exécution CPU hôte avec LLM local

En ligne : déploiement complet GPU T4

p50 1,81 s · p95 2,41 s : accélération CUDA GPU T4 16 Go · [trikwi-p13-agent-echechs.hf.space](#)



Latences mesurées sur le scénario de démo (notebook 05, 3 répétitions par position).

Les principaux choix techniques

CHOIX D'ARCHITECTURE	ALTERNATIVE ÉVALUÉE	DÉCISION ET JUSTIFICATION TECHNIQUE
Modèle LLM local vs API	API cloud payante	Modèle local Qwen 3.5 (3,2 Go RAM) retenu : 0 € de coût , latence 1,8 s (GPU T4) / 6,3 s (CPU)
Structure documentaire	Chunks bruts 1 000 tokens	Fiches 300–500 tokens avec fil d'Ariane, section et métadonnées scalaires (ECO, FEN)
Gestion du hors-sujet	Seuil cosinus seul	Filtrage déterministe par rayon d'ouverture + seuil filet à 0,58 (5/5 pièges bloqués)

Chaque choix d'architecture a été comparé et validé sur des bancs de mesure reproductibles.

Détails complets des bancs d'essais : documentation technique et annexes C-D.

Déploiement et coûts

LOCAL : POC complet

- **7 conteneurs Docker** (`docker compose up` / `./demarrer.sh`)
- Modèle LLM local sur l'hôte (Ollama)
- Installation fraîche mesurée : **prête en 2 min 09**

Coût du POC : 0,00 €

Données libres (CC0, CC BY-SA), composants open source, hébergement local sans frais d'API.

EN LIGNE : Déploiement complet GPU T4

- **Hugging Face Spaces** (mono-conteneur Docker GPU T4 16 Go)
- Modèle LLM Qwen + Stockfish + Milvus Lite embarqués
- Pipeline CI/CD **GitHub Actions** (déploiement automatique sur push main)
- Accès direct : `trikwi-p13-agent-echecs.hf.space`

Projection Cloud : ~0,0025 € / requête (0,25 centime)

Option Claude Haiku mesurée : < 0,10 € par élève et par mois pour 30 analyses complètes.

Perspective : analyse vidéo

vidéo → extraction d'images → détection échiquier → position **FEN** → **agent existant**

1. Faisabilité

Détection visuelle 2D sur screencasts et reconstruction FEN validée par python-chess.

2. Intégration MCP

Architecture modulaire (4 serveurs FastMCP) réutilisant directement le moteur et la base vectorielle du POC.

3. Stratégie MVP

Transcripts et vidéos sous licence Creative Commons (sécurisation juridique CGU YouTube).

Étude technique réalisée (note de cadrage, architecture MCP, modèle de coûts) : développement hors périmètre du POC.

BILAN

Ce que le POC démontre

Agent fonctionnel

Reconnaissance théorique immédiate, bascule moteur sur sortie de théorie, explications sourcées.

Déjà intégré (Bonus)

Mode Robot Stockfish avec niveau Elo ajustable (1200 à 2200) et mode saisie libre avec relais Chessbot.

Déploiement éprouvé

Initialisation locale en 2 min 09 et vitrine publique déployée sur Hugging Face Spaces.


Prochaines évolutions

Phase pilote espoirs FFE, serveurs d'outils MCP pour l'analyse vidéo, extension aux 500 codes ECO.


→ **Place à la démonstration en direct et aux échanges**

A — Les sources de données en détail

SOURCE	CONTENU	VOLUMÉTRIE	LICENCE
Référentiel chess-openings	3 810 ouvertures nommées, 500 codes ECO	~500 Ko	CC0
API Lichess Explorer	stats masters (2 M+ parties) par position	temps réel + cache 24 h	CC0
Corpus « Wikichess »	225 art. FR + 3 026 p. EN → 161 retenues (manifeste signé) → 477 fiches	8 ouvertures cibles	CC BY-SA
YouTube Data API v3	métadonnées uniquement, jamais les fichiers	~300 unités réelles, cache 7 j	CGU respectées



couverture réelle des 8 ouvertures (FR/EN)




longueurs des fiches (moy. 244 tokens, assumé)

Formats bruts (TSV, JSON, wikitext, UCI) et normalisation : documentation technique.

B — Le protocole d'évaluation en détail


Le gold set : 25 questions étiquetées à la main, **figées avant tout réglage** — 15 directes (FR + EN), 5 par position (FEN), 5 pièges où la bonne réponse est de s'abstenir. **Runs A vs B** (MLflow) : A « naïf » (chunks 1 000, top-3, sans filtre) vs B « soigné » (300–500 + fil d'Ariane, top-5, filtre ECO) — recall@5 et MRR 1,0 partout → l'étalon v1 mesure le routage ; la vraie différence (qualité des fiches transmises) exige des labels fins.



Run Name	Created	Dataset	Duration	Source	Models
B_soigne	38 seconds ago	-	399ms	evaluer...	-
A_naif	38 seconds ago	-	78ms	evaluer...	-
B_soigne	1 minute ago	-	50ms	evaluer...	-
A_naif	1 minute ago	-	462ms	evaluer...	-

Le cahier d'expériences MLflow réel (gold-set-rag). Mesure d'adoption des embeddings : préfixe d'instruction → séparation 0,29 → 0,50 (notebook 02).

C — La décision d'abstention, l'histoire complète



1 • **Préjudice mesuré** (notebook 05) : une question hors corpus faisait citer 5 fiches adjacentes en sources.

2 • **Le seuil pur est impossible** (notebook 07, ci-contre) : pièges grossiers $\leq 0,548$, mais entrelacement 0,618–0,663 — et les vraies questions scorent bas (démonstration : 0,629).

3 • **La règle des rayons signés** : le corpus n'est consulté que dans un rayon établi par la position (ECO) ou nommé dans la question ; hors manifeste → zéro fiche + réponse honnête. Filet à 0,58. **5/5 pièges bloqués par construction, 0 légitime sacrifiée** — tests garde-fous versionnés.

D — Le choix du LLM en détail

Décision prise sur mesures (campagne de 4 modèles locaux, 22/08) — et révisée par elles : le plan initial (API) est tombé devant les chiffres du local.

OPTION	COÛT	VERDICT MESURÉ
qwen3.5:4b local (Ollama) ✓	0 €	3,2 Go de RAM · 3–7 s/réponse · FR correct avec garde-fous (faits annotés, temp 0,2)
Claude Haiku 4.5 (API)	1 \$ / 5 \$ par M tokens	option qualité — activable par variable d'environnement
Gabarit déterministe	0 €	repli toujours juste : réponse exacte et sourcée même sans LLM

Réversible par conception : le LLM ne fait que la mise en forme finale (LLM_PROVIDER) — il n'est jamais la source de vérité. Un mot de théorie : un LLM prédit le mot suivant, il est fait pour être plausible, pas pour être vrai — d'où les faits annotés (« Fc5 — le Fou va en c5 »), la basse température et le repli déterministe.

E — Le modèle de données

Milvus — collection `openings_kb`

CHAMP	RÔLE
<code>vector</code> float(1024)	embedding — cosinus, index HNSW
<code>text</code>	le passage (fil d'Ariane + section)
<code>eco</code> · <code>ouverture</code> · <code>fen_ref</code> · <code>lang</code>	filtres scalaires (règle des rayons)
<code>source_url</code> · <code>licence</code>	attribution des sources
<code>content_hash</code> · <code>ingested_at</code>	idempotence, fraîcheur

MongoDB — les caches

COLLECTION	PARTICULARITÉ
<code>explorer_cache</code>	théorie par FEN — TTL 24 h
<code>eval_cache</code>	évals Stockfish — sans TTL (déterministe)
<code>videos_cache</code>	métadonnées par ouverture — TTL 7 j
<code>eval_runs</code>	résultats gold set — traçabilité

Clé de jointure transverse : le `FEN` normalisé — la même qui reliera les positions extraites des vidéos (partie 2).