

FÉDÉRATION FRANÇAISE DES ÉCHECS × CAVALIER DATA

Un coach IA pour les ouvertures d'échecs

Accompagner les jeunes espoirs pendant leur entraînement autonome

Richard Hugou

IA Engineer — Soutenance de projet — Août 2026

Besoin et contexte

Le constat à la FFE

- **60 000 licenciés**, dont ~60 % de jeunes espoirs.
- Quelques centaines d'entraîneurs qualifiés sur le territoire.
- **Le goulot d'étranglement est humain** : impossible d'offrir un suivi quotidien individualisé le soir ou entre les rondes de tournoi.

Le cas d'usage : Léa, 12 ans

- Prépare ses championnats et veut réviser son répertoire ce soir.
- Son entraîneur n'est pas disponible.
- **Mission du POC** : un agent interactif disponible à la demande pour l'accompagner *pendant* qu'elle joue.

Les 4 capacités attendues de l'agent


1. Répertoire théorique : proposer les coups joués par les maîtres.

2. Explications sourcées : justifier les plans avec sources fiables.

3. Vidéos ciblées : recommander les cours pertinents.

4. Évaluation moteur : analyser objectivement toute sortie de théorie.

Démonstration en vidéo



Loom · 3-4 coups · Conseils RAG · Sortie de théorie
Stockfish

Parcours utilisateur

1. Orientation & Choix

L'élève choisit son camp (ex : les Blancs). L'échiquier s'oriente immédiatement et l'ouverture cible (Partie Italienne) est sélectionnée.

2. Jeu théorique

L'élève joue ses coups sur le plateau. L'agent joue automatiquement la réponse des maîtres Lichess la plus fréquente (1.e4 e5, 2.Cf3 Cc6).

3. Conseils sourcés


À 3.Fc4, « Demander à Chessbot » affiche les coups des maîtres, les flèches tactiques, la synthèse sourcée et la vidéo YouTube associée.

4. Déviation moteur

Sur un coup hors théorie (ex: 4.g4?!), l'agent bascule instantanément sur Stockfish pour fournir une évaluation objective chiffrée (-1,47 cp).

Principe directeur : les faits proviennent des moteurs spécialisés, le LLM intervient uniquement pour la formulation.

Architecture



Clé pivot FEN

La chaîne transmet la position standardisée de bout en bout sans ambiguïté.


Milvus vs MongoDB

Milvus stocke la connaissance vectorisée ; **MongoDB** gère le cache applicatif transverse.

Routage déterministe

Le seuil de parties maîtres décide du passage théorie/moteur de manière fiable.

Orchestration



Scénario nominal (Italienne)

Coup 3.Fc4 → Lichess fournit Fc5/Cf6 → Milvus extrait les fiches du rayon → le LLM rédige le plan stratégique.

Scénario de déviation (Sortie)

Coup 4.g4?! → < 5 parties de référence → bifurcation immédiate vers Stockfish → évaluation -1,47 cp.

Recherche sémantique



Espace vectoriel unifié

Modèle multilingue (1024 dimensions) alignant naturellement les concepts en français et anglais.

Filtrage par rayon d'ouverture

Recherche restreinte au rayon actif : empêche la récupération de sources hors du périmètre concerné.

Performances mesurées

Recherche exécutée en **7 à 11 ms** · Séparation sémantique cible/hors-sujet portée de 0,29 à **0,50**.

Données


4 sources documentaires complémentaires :

- **Référentiel des ouvertures** : nomenclature et codes ECO officiels
- **Lichess Explorer** : base de 2 M+ parties et statistiques maîtres
- **Wikipédia / Wikibooks** : corpus encyclopédique structuré
- **YouTube** : métadonnées et horodatages des cours vidéo

Pipeline ETL rejouable et idempotent :

extraction (manifeste signé) → nettoyage → fiches → vecteurs → Milvus

Périmètre validé : **156 pages extraites → 477 fiches structurées** (95 positions FEN calculées, 0 échec).



Entonnoir réel du corpus (notebook 03) : 3 251 pages disponibles → 161 retenues → 477 fiches.

Protocole de mesure

1. Scénarios évalués

- Ligne théorique nominale (Italienne).
- Déviation hors théorie (`4.g4?!`).
- Questions libres d'explication tactique.

2. Bancs automatisés

- **56 positions** validées par `python-chess`.
- **Gold Set 25 questions** sous MLflow.
- **5 pièges d'abstention** hors domaine.
- **12 runs de latence** (4 positions × 3 répétitions).


3. Environnements testés

- **Local** : CPU hôte avec LLM Ollama.
- **Cloud** : Hugging Face Space avec GPU NVIDIA T4 16 Go VRAM et Ollama CUDA.

Toutes les mesures sont reproductibles via les notebooks et scripts de test du dépôt.

Résultats et performances

Indicateur clé	Objectif	Résultat mesuré
Coups illégaux en sortie	0	0 sur 56 testés
recall@5 (Gold Set 25 questions)	>= 0,80	1,0 (tracé MLflow)
Abstention sur les pièges	5 / 5	5 / 5 (filtrage par rayon)
Réponses avec sources valides	100 %	100 % (garanti par pipeline)
Recherche vectorielle Milvus	< 100 ms	7–11 ms (p95)
Latence Cloud GPU T4 (avec LLM)	p95 < 8 s	1,81 s (p50) · 2,41 s (p95)
Latence Local CPU (avec LLM)	p95 < 8 s	2,69 s (p50) · 6,35 s (p95)
Coût d'API LLM	0 €	0,00 € (modèle open source)



Latences mesurées sur le scénario de démo (notebook 05, 3 répétitions par position).

Choix techniques

Choix d'architecture	Alternative évaluée	Décision et justification technique
Modèle LLM open source	API cloud payante	Modèle Qwen (3,2 Go) retenu : 0 € de coût d'API , p95 2,41 s sur T4 GPU, souveraineté des données
Structure documentaire	Chunks bruts 1 000 tokens	Fiches 300–500 tokens avec fil d'Ariane, section et métadonnées scalaires (ECO, FEN)
Gestion du hors-sujet	Seuil cosinus seul	Filtrage déterministe par rayon d'ouverture + seuil filet à 0,58 (5/5 pièges bloqués)

Chaque choix technique repose sur une comparaison objective et des mesures reproductibles.

Déploiement et coûts


LOCAL : POC complet

- **7 conteneurs Docker** (`docker compose up / ./demarrer.sh`)
- Modèle LLM local sur l'hôte (Ollama)
- Initialisation mesurée : **prête en 2 min 09**
- Coût infrastructure : **0,00 €**

EN LIGNE : Déploiement GPU T4

- **Hugging Face Spaces** (mono-conteneur Docker GPU T4 16 Go)
- Modèle Qwen + Stockfish + Milvus Lite embarqués
- CI/CD **GitHub Actions** (déploiement automatique sur push main)
- Coût infrastructure : **0,40 \$/h** (à l'usage) · Accès : `trikwi-p13-agent-echecs.hf.space`

Analyse vidéo



Aujourd'hui (POC)

Recommandation globale de vidéos par ouverture :
« Voici 3 vidéos sur la Partie Italienne. »

Après analyse vidéo (Étude)

Recommandation directe au timestamp exact :
« Cette position est expliquée à 4:32 dans cette vidéo. »

Étude de faisabilité réalisée — développement hors périmètre du POC

Résumé du POC

Agent fonctionnel

Reconnaissance théorique immédiate, bascule moteur sur sortie de théorie, explications pédagogiques sourcées.

Architecture maîtrisée

Orchestration déterministe LangGraph, Stockfish UCI, base vectorielle Milvus, cache transverse MongoDB.

Performances validées

0 coup illégal sur 56 positions, latence sous 2,5 s sur GPU Cloud T4 (p95 = 2,41 s).

Déploiement éprouvé

Conteneurisation locale reproductible (2 min 09) et déploiement cloud GPU opérationnel sur Hugging Face Spaces.

→ Place à la démonstration en direct et aux échanges.

Merci.

Richard Hugou

IA Engineer — Cavalier Data

Dépôt : <https://github.com/richardhugou/p13-agent-ia-echecs>

Vitrine : <https://trikwi-p13-agent-echecs.hf.space>