

Étude de faisabilité & coûts — système d'analyse vidéo (build + opex)

Méthode : hypothèses explicites × prix unitaires publics (ordres de grandeur d'août 2026), 3 scénarios de volume, analyse de sensibilité. La méthode est le livrable autant que les chiffres : tout est recalculable en changeant une hypothèse du §1.

1. Hypothèses de dimensionnement (le contrat de lecture)

Hypothèse	Valeur retenue	Justification
Durée moyenne vidéo	15 min	standard du format pédagogique
Échantillonnage frames	1 frame / 5 s → 180 frames/vidéo	compromis précision temporelle / coût (sensibilité §6)
Frames clés conservées (changement de position)	~30/vidéo × ~100 Ko ≈ 3 Mo/vidéo	on ne stocke jamais la vidéo, seulement les frames retenues
Régime de vision	2D screencast (MVP) : vision classique CPU ~50 ms/frame	majorité du contenu pédagogique ; le 3D est en V2
Compute pipeline complet	~3 min CPU/vidéo (extraction + détection + FEN + alignement)	ordre de grandeur — à confirmer sur le pilote de 100 vidéos
Transcription	sous-titres YouTube quand disponibles (hypothèse : ~70 % du corpus) ; sinon API type Whisper ≈ 0,006 \$/min	poste dominant, voir sensibilité
Enrichissement LLM (résumé, alignement sémantique)	~5k tokens in + 1k out par vidéo (modèle éco, tarif type Haiku : 1 \$/M entrée, 5 \$/M sortie)	≈ 0,01 \$/vidéo
Périmètre juridique MVP	vidéos Creative Commons uniquement + transcripts	lève le risque CGU (cf. note §4.1)
TJM développement	500 € (profil junior encadré, marché France) — curseur ajustable	pour le build

2. Coûts de BUILD (jours-homme × TJM)

Phase	Contenu	Charge estimée	Coût (TJM 500 €)
MVP	Pipeline transcripts + vidéos CC + détection 2D, serveurs MCP srv-youtube/srv-vision/srv-connaissances, intégration à l'agent POC, pilote sur 100 vidéos + mesure de précision	30–40 j-h	15–20 k€

Phase	Contenu	Charge estimée	Coût (TJM 500 €)
V1	Alignement fin transcript↔position↔timestamp, monitoring qualité, back-office de contrôle, industrialisation (CI, IaC légère)	40–60 j-h	20–30 k€
V2	Plateaux 3D : dataset (annotation si nécessaire : 5–10 k€), fine-tuning vision (GPU : quelques dizaines d'heures de T4, coût GPU marginal : < 50 €), tracking expériences (MLflow/W&B), déploiement inference	40–80 j-h	20–40 k€ (+ data)

Message clé : dans ce projet, le coût est dans les **jours-homme**, pas dans le GPU.

3. OPEX mensuel — 3 scénarios

Postes variables (par vidéo) : compute $\approx 0,007 \$$; transcription (30 % des vidéos sans sous-titres $\times 0,09 \$$) $\approx 0,03 \$$; LLM $\approx 0,01 \$$; stockage marginal $\approx 0,001 \$/\text{mois}$. $\approx$ **0,05 \$/vidéo variable** (0,14 \$ si transcription API à 100 %). Postes fixes : VM pipeline + bases (Milvus/Mongo) + monitoring $\approx 50\text{--}100 \$/\text{mois}$ (mutualisables avec l'infra de l'agent) ; à 10 k vidéos/mois : 150–300 \$/mois.

Poste	S1 : 100 vidéos/mois	S2 : 1 000 vidéos/mois	S3 : 10 000 vidéos/mois
Compute (extraction+vision)	~1 \$	~7 \$	~70 \$
Transcription (30 % API)	~3 \$	~27 \$	~270 \$
LLM enrichissement	~1 \$	~10 \$	~100 \$
Stockage frames (cumul 1re année)	< 1 \$	~1 \$ (3 Go/mois)	~8 \$ (30 Go/mois)
Fixe infra	50–100 \$	50–100 \$	150–300 \$
Total/mois	~55–105 \$	~95–145 \$	~600–750 \$
Coût complet / vidéo	~0,6–1,1 \$ (le fixe domine)	~0,10–0,15 \$	~0,06–0,08 \$

4. Comparaison avec l'alternative manuelle (le chiffre qui vend)

Indexation humaine : 15–30 min/vidéo $\times \sim 30 \text{ €/h}$ chargé $\approx$ **7,5–15 €/vidéo**, contre **~0,10–0,15 €/vidéo** automatisé (S2) $\rightarrow$ facteur **$\times 50$ à $\times 100$** , hors qualité/exhaustivité. (Et l'humain reste dans la boucle en contrôle qualité par échantillonnage : $\approx 2 \text{ h/mois}$ au scénario S2, contrôle par échantillonnage de 2 %.)

5. Faisabilité technique — verdict par brique

Brique	Maturité	Verdict
Détection échiquier 2D + FEN	Vision classique, état de l'art solide	Faisable MVP

Brique	Maturité	Verdict
Transcripts + extraction des coups cités	NLP simple + python-chess	Faisable MVP, le meilleur ratio valeur/coût
Alignement position ↔ timestamp	Croisement frames/transcript	Faisable V1, précision à mesurer sur pilote
Plateaux 3D filmés	Modèles publics + jeux de données publics (ChessReD, ~10 800 images) mais écart de domaine réel	Risqué — V2 seulement, après pilote
Cadre juridique hors CC	Négociation/licences	Bloquant tant que non traité — décision FFE

6. Sensibilité (les 3 curseurs qui changent la facture)

1. **Échantillonnage** ×3 (1 frame/s au lieu de 1/5 s) → compute & stockage ×3, précision temporelle accrue : réserver aux vidéos « premium ».
2. **Transcription** : 100 % API (×3 sur le poste dominant) vs modèle local auto-hébergé (variable ≈ 0, mais + infra GPU/CPU et + maintenance) : bascule pertinente au-delà de ~5 000 vidéos/mois.
3. **Volume** : sous ~500 vidéos/mois, le fixe domine → mutualiser l'infra avec l'agent existant est la vraie économie.

7. Risques économiques & go/no-go

- Risques : changement CGU/quotas YouTube ; dérive du périmètre vers le 3D trop tôt ; sous-estimation du contrôle qualité humain.
- **Critères go/no-go après pilote MVP (100 vidéos)** : précision FEN ≥ 90 % sur l'échantillon annoté (~500 frames) ; coût complet $\leq 0,20$ €/vidéo ; ≥ 30 % des recommandations de l'agent enrichies d'un timestamp ; validation juridique du sourcing.

8. Recommandation

Lancer le **MVP « CC + 2D + transcripts »** (15–20 k€, opex ~100–150 \$/mois au régime S2), mesurer sur un pilote de 100 vidéos, et ne décider du V2 « 3D » (le seul qui exige un vrai entraînement de modèle) qu'au vu des métriques du pilote. Roadmap détaillée : note §9.